コンピュータリテラシ発展 ～Pythonを学ぶ～

第9回：Excel作業の前工程・後工程の自動化

(shimizu@info.shonan-it.ac.jp)

今回の授業内容

今回の授業内容

-
-
- CSV
-

前回の課題解説

前回の課題解説

-
-

解答例

https://colab.research.google.com/drive/1il56vahBZGQGQwkpblwzJ92_Eodw6xGf?usp=sharing

文字列操作

文字列操作

- Python
  -
  - 正規表現
-
  - https://www.tohoho-web.com/ex/regexp.html

文字列操作

-

- Google Drive text_search
- text_search file.txt
-

東京タワーの郵便番号は105-0011で、東京スカイツリーの郵便番号は131-0045です。

文字列操作

-

```
import os
# 作業場所に「text_search」フォルダを作成する
os.makedirs('/content/drive/MyDrive/???/text_search', exist_ok=True)

#  「text_search」フォルダに「file.txt」ファイルを作成して文章を入力する
with open('/content/drive/MyDrive/???/text_search/file.txt', 'x') as f:
  f.write('東京タワーの郵便番号は105-0011で、東京スカイツリーの郵便番号は131-0045です。')
```

文字列操作

-
- in演算子
  -
  - True
  - False

文字列操作

-
- `find()` メソッド
  -
  - 0

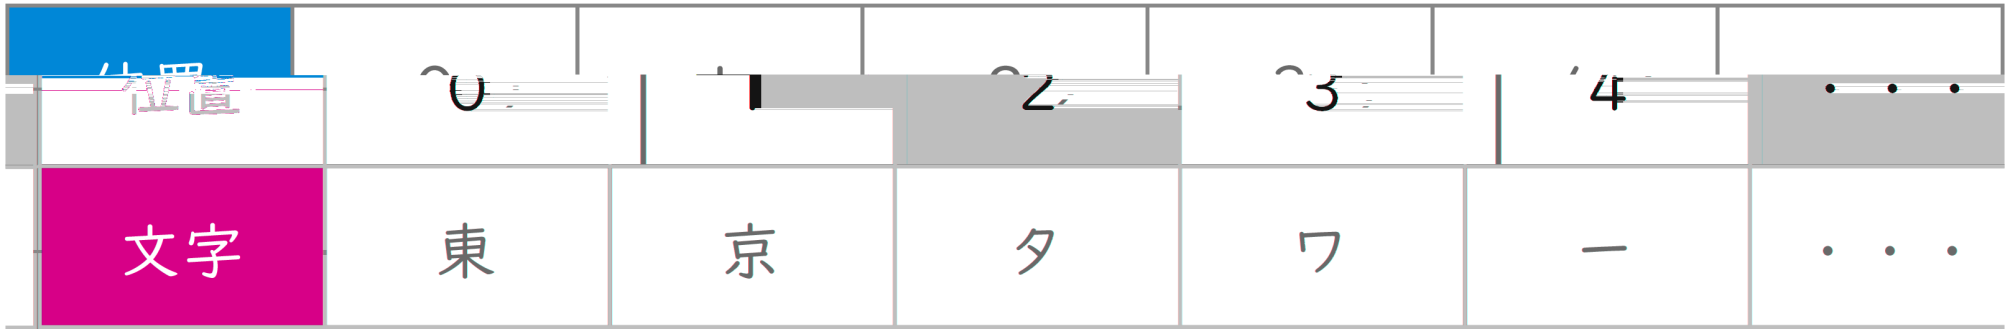

文字列操作

-
- in演算子
- `find()`メソッド

```
with open('/content/drive/MyDrive/???/text_search/file.txt', encoding='UTF-8') as f:
  text = f.read()

if 'タワー' in text:
  fd = text.find('タワー')
  print('タワーという文字列が' + str(fd + 1) + '字目に含まれています')
else:
  print('タワーという文字列は含まれていません')
```

正規表現を使って文字列を検索

-
  -
  -
    - https://w.wiki/5SGg
    - https://docs.python.org/ja/3/library/re.html
    - https://www.tohoho-web.com/ex/regexp.html

正規表現を使って文字列を検索

-
  - ^(　　)　.(　　)　*(　　)　\d
  -

メタ文字の種類と意味

表現	意味
.	1
*	0 0 =
{N}	N
^	
$	
A|B	A B 1

メタ文字の種類と意味

表現	意味
[X]	[] 1
[X-Y]	[] - 1
[^X]	[] X 1
\d	[0-9]
\D	
\w	

正規表現を使って文字列を検索

-
  -
  - 数字３桁-数字４桁
  - `\d\d\d-\d\d\d\d`

正規表現を使って文字列を検索

- Python
  - `re`
    - regular expression
    -
    -

正規表現を使って文字列を検索

- Python
  - `re`
    - `findall()`
      -
      -
      -

正規表現を使って文字列を検索

-
  - `re`
    - `findall()`
      -
        -
        - \ raw

正規表現を使って文字列を検索

- Python
  - `re` `findall()`

```
import re # reモジュールをインポート

# 検索対象のファイルのパスを指定
file_path = '/content/drive/MyDrive/???/text_search/file.txt'

# ファイルをUTF-8エンコーディングで読み込みモードで開く
with open(file_path, encoding='UTF-8') as f:
  # ファイルの内容を読み取り、正規表現を使って郵便番号のリストを抽出
  # 正規表現 r'\d\d\d-\d\d\d\d' は 'xxx-xxxx' 形式の郵便番号にマッチする
  postal_code_list = re.findall(r'\d\d\d-\d\d\d\d', f.read())

# 抽出された郵便番号のリストを表示
print(postal_code_list)
```

正規表現を使って文字列を検索

- Python
  - `re`
    - `compile()`
      -
      -

正規表現を使って文字列を検索

- Python
  - `re` `compile()`

```
import re

file_path = '/content/drive/MyDrive/???/text_search/file.txt'

# 郵便番号を表す正規表現パターンをオブジェクト化
# 正規表現 r'\d\d\d-\d\d\d\d' は 'xxx-xxxx' 形式の郵便番号にマッチする
postal_code_regex = re.compile(r'\d\d\d-\d\d\d\d')

with open(file_path, encoding='UTF-8') as f:
  # ファイルの内容を読み取り、正規表現を使って郵便番号のリストを抽出
  postal_code_list = postal_code_regex.findall(f.read())

print(postal_code_list)
```

正規表現を使って文字列の位置を調べる

-
- `search()`
  -
  -
  -

正規表現を使って文字列の位置を調べる

-
- `search()`

```
import re

file_path = '/content/drive/MyDrive/???/text_search/file.txt'

with open(file_path, encoding='UTF-8') as f:
  # ファイルの内容を読み取り、正規表現を使って最初にマッチする郵便番号を検索
  # 正規表現 r'\d\d\d-\d\d\d\d' は 'xxx-xxxx' 形式の郵便番号にマッチする
  print(re.search(r'\d\d\d-\d\d\d\d', f.read()))
```

正規表現を使って文字列の位置を調べる

-
- `search()`
    -
        - `group()`:
        - `start()`:
        - `end()`
        - `span()`:

正規表現を使って文字列の位置を調べる

-
- `search()`

```
file_path = '/content/drive/MyDrive/???/text_search/file.txt'
postal_code_regex = re.compile(r'\d\d\d-\d\d\d\d')

with open(file_path, encoding='UTF-8') as f:
  # ファイルの内容を読み取り、正規表現を使って最初にマッチする郵便番号を検索
  postal_code_match = postal_code_regex.search(f.read())

  if postal_code_match:   # マッチする郵便番号が見つかった場合
    print(postal_code_match)           # マッチした結果のMatchオブジェクトを表示
    print(postal_code_match.group())   # マッチした文字列自体を表示
    print(postal_code_match.start())   # マッチした文字列の開始位置を表示
    print(postal_code_match.end())     # マッチした文字列の終了位置を表示
    print(postal_code_match.span())    # マッチした文字列の開始位置と終了位置のタプルを表示
```

正規表現を使って文字列の位置を調べる

-
- `search()`

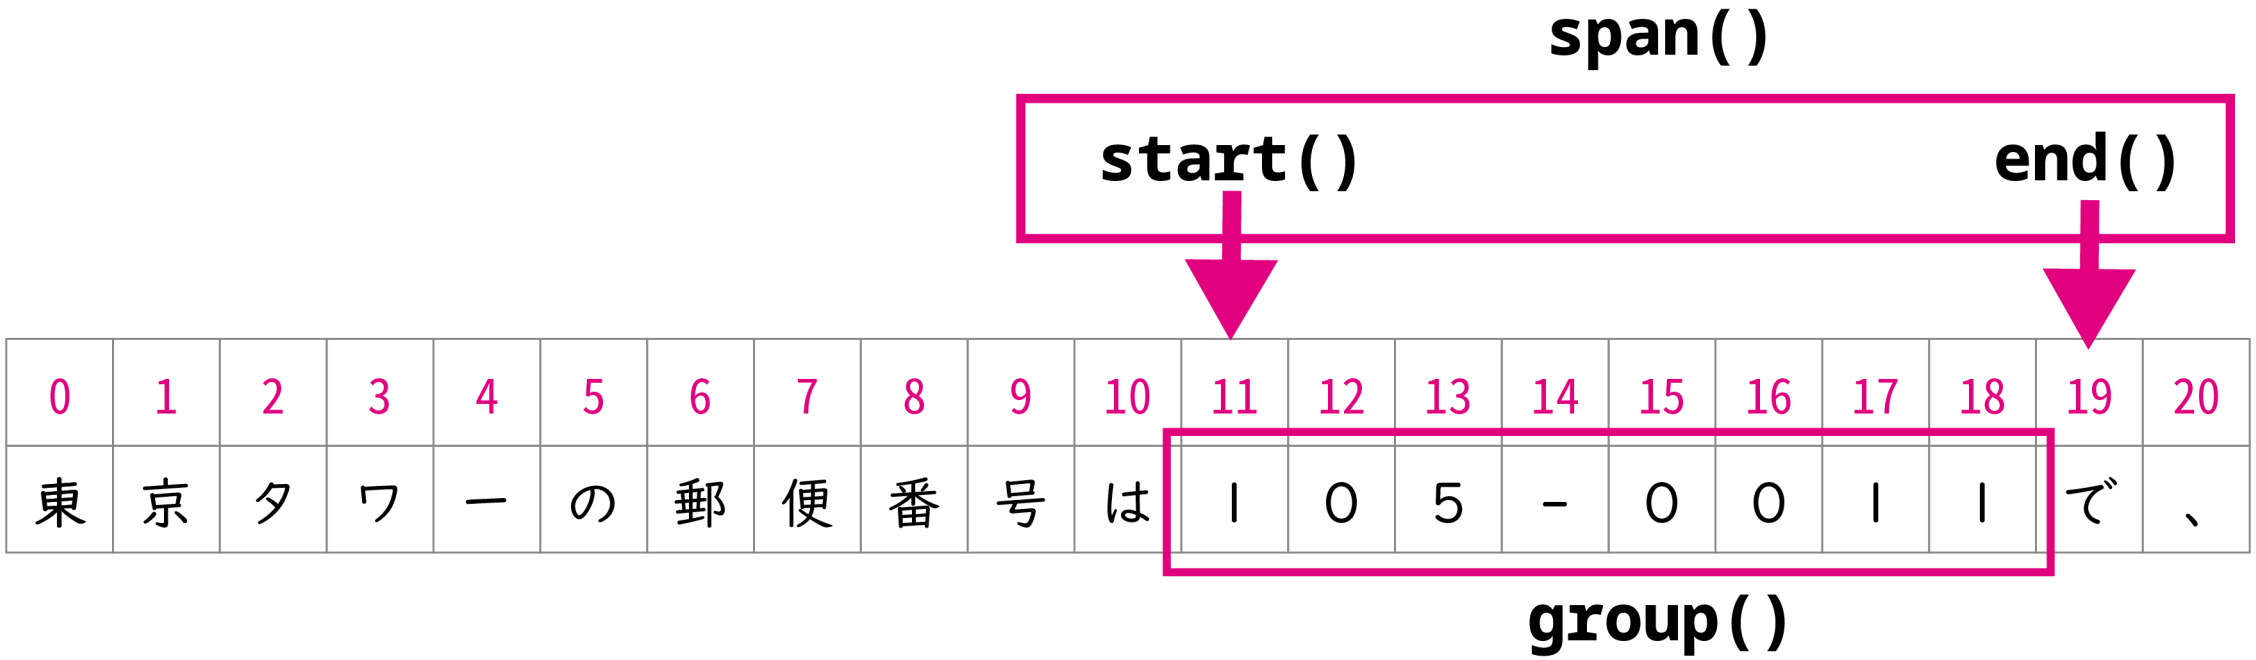

文字列の置換

-
- `sub()`
  -
  -
  -

文字列の置換

-
- `sub()`
- 東京 Tokyo

```
import re

file_path = '/content/drive/MyDrive/???/text_search/file.txt'

with open(file_path, encoding='UTF-8') as f:
  # ファイルの内容をすべて読み取り、正規表現を使って文字列を置換
  # '東京' という文字列を 'Tokyo' に置換する
  text_mod = re.sub('東京', 'Tokyo', f.read())

  # 置換後のテキストを表示
  print(text_mod)
```

CSVデータの処理

CSVの出力

- CSV
  - Comma-Separated Values
  - ,
- `csv`
  - python　CSV　　csv
  -

CSVの出力

- CSV CSV
- CSV `writer()`
- `writer()` `delimiter`
- `delimiter` `,`
- `writerow()` CSV

CSVの出力

- CSV sample.csv

```
import os, csv # os, csvモジュールをインポート

# CSVファイルを保存するためのフォルダのパスを指定
path = '/content/drive/MyDrive/???/CSV/'

# 指定されたパスにフォルダを作成．既に存在する場合はエラーを出さずに無視する
os.makedirs(path, exist_ok=True)

# 'sample.csv'ファイルを新規作成モード（'x'）で開き，改行コードを指定してファイルオブジェクトを取得
with open(path + 'sample.csv', 'x', newline='') as f:
  # csv.writerオブジェクトを作成し，カンマ区切り（delimiter=','）に設定
  w = csv.writer(f, delimiter=',')
  # 1行目のデータ ['1', '2', '3'] をCSVファイルに書き込む
  w.writerow(['1', '2', '3'])
  # 2行目のデータ ['4', '5', '6'] をCSVファイルに書き込む
  w.writerow(['4', '5', '6'])
```

CSVの出力

- CSV `csv`

CSVの加工

- CSV
- `pandas`
- `pandas` CSV

CSVの加工

- pandas CSV `read_csv()`
- CSV `DataFrame`
- `DataFrame` 0

  `df.loc[0]=['10','20','30']`
- `to_csv()` CSV
- `index=False` `header=None`

CSVの加工

- pandas　　CSV

```
import pandas as pd # pandasモジュールをインポート

path = '/content/drive/MyDrive/???/CSV/'

# 'sample.csv'ファイルを読み込み、データフレームに格納
# header=None はCSVファイルにヘッダー行がないことを示す
df = pd.read_csv(path + 'sample.csv', header=None)
# データフレームの最初の行（インデックス0）を新しいデータ ['10', '20', '30'] で置き換える
df.loc[0] = ['10', '20', '30']
# 変更されたデータフレームを新しいCSVファイル 'sample2.csv' に保存
# index=False は行番号を保存しないことを示す
# header=False はヘッダー行を保存しないことを示す（誤りを修正）
df.to_csv(path +'sample2.csv', index=False, header=None)
```

CSVの加工

- pandas
- pandas
-
- Qiita
- https://pandas.pydata.org/
- https://qiita.com/tags/pandas

課題

課題

- Moodle SCfCL-9th-prac.ipynb Colab
- File > Download > Download .ipynb .ipynb
- **.ipynbファイル** Moodle
- **6月20日(木) 20時まで**